

Synthèse des Expérimentations NLI

Comparaison des méthodes PEFT (IA³ vs LoRA) en conditions Few-Shot

Projet TER M1 – Rapport d’expérimentation

27 avril 2026

1 Contexte : Full-Data vs Few-Shot en NLI

Le cadre de ce projet de TER vise à évaluer la capacité des modèles de langage pré-entraînés (CamemBERT, FlauBERT) à résoudre des tâches d’inférence en langage naturel (NLI) en français. Nous avons commencé par définir la borne supérieure des performances (*Full-Data Fine-Tuning*) : avec accès à la totalité d’un dataset (plus de 50 000 exemples), un modèle CamemBERT atteint entre 65% et 85% d’exactitude.

Toutefois, la disponibilité de milliers de données annotées est rare en entreprise. L’objectif de notre phase d’expérimentation croisée est d’étudier l’effondrement des performances en condition de privation de données (*Extreme Few-Shot*, soit entre 8 et 128 exemples).

2 Approche Technique : Comparaison LoRA et IA³

Pour éviter l’oubli catastrophique et le sur-apprentissage immédiat qui se produisent lorsqu’on fine-tune un modèle entier sur 8 exemples, nous avons utilisé des méthodes de fine-tuning efficaces en paramètres (PEFT). Nous avons implémenté et comparé deux architectures :

- **LoRA** : Injection de matrices de bas rang. Bien qu’efficace, elle modifie environ $\sim 1.06\%$ des poids du modèle.
- **IA³** : Méthode reposant sur un redimensionnement vectoriel (*scaling*) des activations. Il s’agit d’une approche beaucoup plus drastique et isolée, modifiant à peine $\sim 0.58\%$ des poids corticaux.

L’objectif de cette étude est de déterminer si la baisse radicale de paramètres offerte par l’IA³ permet une meilleure résilience en régime de très basse donnée face à LoRA.

3 Résultats 1 : L’Intra-Dataset (GQNLI $\rightarrow$ GQNLI)

La première phase expérimentale tire un échantillon N (stratifié) du dataset GQNLI et évalue le modèle sur le test set de ce même domaine. 60 exécutions (runs) ont été générées sur plateforme Kaggle.

Comme l’illustre la figure 1, **l’approche IA³ obtient la victoire absolue sur le segment Extreme Few-Shot.** Dès le palier de 8 exemples, CamemBERT + IA³ atteint **40.0%** d’accuracy (battant le hasard) tandis que CamemBERT + LoRA stagne sous les 38%. Sur le plafond des 128 exemples, IA³ maintient son avance en perçant la barre des **50.0%**. La "légèreté" paramétrique de l’IA³ empêche le modèle de mémoriser mécaniquement le bruit des 8 phrases, favorisant une abstraction de la tâche et confirmant la supériorité de cette méthode pour des corpus pauvres.




FIGURE 1 – Évolution de l'accuracy et du Score F1 (Macro) en fonction du nombre de "shots".

4 Résultats 2 : Le Cross-Dataset (Transfert de Domaine)

L'expérience finale (*Sweep t493ddfp*) cherchait à forcer le modèle à généraliser. Nous lui avons fourni des axiomes de logique formelle mathématiques (dataset **FraCaS**) et l'avons testé sur des descriptions d'articles Wikipédia (**GQNLI-FR**).




FIGURE 2 – Effondrement catastrophique en transfert Cross-Dataset (FraCaS vers GQNLI).

Les résultats dévoilent un mécanisme fascinant du NLI profond : **une chute immuable à 20.0%** d'exactitude (pire que le hasard de 33%, pré-disant la classe "Neutre" pour l'intégralité du set de test). Durant le Fine-Tuning, le modèle a instantanément percé la structure rigide de FraCaS (atteignant une validation de 100%). Néanmoins, s'agissant de pur "Few-Shot", cette logique mathématique agit comme un format parasite qui détruit la capacité naturelle de compréhension sémantique de GQNLI. C'est la limite ultime démontrée : en Few-Shot, le transfert interdisciplinaire est un échec par défaut.

5 Conclusion

Au terme de ces sweeps complets, nous avons scientifiquement cartographié les limites de l'usage NLI. Le plein-potentiel réside dans le Full-Data ($\sim 80\%$), mais si les budgets ne le permettent pas, une fine couche de restriction IA^3 permet néanmoins d'extirper la moitié des

bonnes réponses possibles ($\sim 50\%$) avec des requêtes rudimentaires, à condition absolue d'opérer le modèle dans son strict domaine d'apprentissage lexical.